

PENERAPAN *LONG SHORT-TERM MEMORY* UNTUK PERAMALAN HARGA EMAS

MUHAMMAD RIZKY NURHAMBALI



**DEPARTEMEN STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
INSTITUT PERTANIAN BOGOR
BOGOR
2023**



@Hak cipta milik IPB University

Hak Cipta Dilindungi Undang-undang

1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :
 - a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah
 - b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.
2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.

PERNYATAAN MENGENAI SKRIPSI DAN SUMBER INFORMASI SERTA PELIMPAHAN HAK CIPTA

Dengan ini saya menyatakan bahwa skripsi dengan judul “Penerapan *Long Short-Term Memory* untuk Peramalan Harga Emas” adalah karya saya dengan arahan dari dosen pembimbing dan belum diajukan dalam bentuk apa pun kepada perguruan tinggi mana pun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka di bagian akhir skripsi ini.

Dengan ini saya melimpahkan hak cipta dari karya tulis saya kepada Institut Pertanian Bogor.

Bogor, Juli 2023

Muhammad Rizky Nurhambali
G14190022



ABSTRAK

MUHAMMAD RIZKY NURHAMBALI. Penerapan *Long Short-Term Memory* untuk Peramalan Harga Emas. Dibimbing oleh YENNI ANGRAINI dan ANWAR FITRIANTO.

Emas merupakan salah satu bentuk investasi dan disebut sebagai aset *safe haven* karena kestabilannya dalam kondisi pasar yang tidak stabil. Peramalan harga emas menjadi penting bagi investor sebagai alat bantu pengambilan keputusan. Penelitian ini bertujuan untuk melihat pengaruh validasi silang dalam memperoleh *hyperparameter* LSTM (*optimizer*, *learning rate*, dan *epoch*) terbaik yang akan digunakan dalam peramalan. LSTM sebagai bagian metode *deep learning* dapat digunakan dalam peramalan selain menggunakan metode klasik. Algoritma ini merupakan pengembangan dari *recurrent neural network* yang banyak digunakan dalam peramalan deret waktu. LSTM dianggap unggul dan mampu meminimalkan kesalahan, serta mampu melakukan peramalan untuk periode jangka panjang dibanding metode lain. *Walk forward validation* dengan skenario pergeseran jendela (tahunan, semester, dan kuartal) sebagai bentuk validasi silang digunakan untuk melihat keakuratan metode. Data yang digunakan berasal dari *World Gold Council* dengan periode data harian untuk tanggal 1 Januari 2003 sampai dengan 20 Januari 2023. *Optimizer* yang digunakan adalah *adam* dan *RMSPProp* dengan nilai *learning rate* 0,01; 0,001; dan 0,0001, serta nilai *epoch* 100, 500, dan 1000. Model terbaik adalah model dengan nilai MAPE terkecil sebesar 12,41% pada proses validasi menggunakan *optimizer* *RMSPProp*, nilai *learning rate* 0,01, dan *epoch* 100. Hasil peramalan menunjukkan kecenderungan harga emas untuk meningkat dalam delapan tahun mendatang.

Kata kunci: *deep learning*, emas, *hyperparameter*, LSTM, peramalan.

@Hak Cipta Dilindungi Undang-undang

1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :
 - a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah
 - b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.
2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.

ABSTRACT

MUHAMMAD RIZKY NURHAMBALI. Implementation of Long Short-Term Memory for Gold Prices Forecasting. Supervised by YENNI ANGRAINI and ANWAR FITRIANTO.

Gold is a form of investment and is referred to as a safe haven asset because of its stability in unstable market conditions. Gold price forecasting is important for investors as decisions making tool. This study aims to study the effect of cross-validation in obtaining the best LSTM hyperparameters (optimizer, learning rate, and epoch) to be used in forecasting. LSTM as part of deep learning methods can be used in forecasting beside the classical method. Algorithm in the LSTM is developed based on a recurrent neural network that is widely used in time series forecasting. It was found that the LSTM is superior compared to other methods for its ability to minimize errors and to forecast for long-term periods. Walk forward validation with window shift scenarios (annual, semester, and quarter) as a form of cross validation is used to see the accuracy of the method. The data used came from the World Gold Council with daily data periods for January 1, 2003, to January 20, 2023. The optimizer used is adam and RMSProp each with learning rate values of 0.01; 0.001; and 0.0001, and with epoch values of 100, 500, and 1000. The best model was the model with the smallest MAPE value of 12.41% in the validation process using an optimizer RMSProp, a learning rate of 0.01, and epoch value of 100. Forecasting results show a tendency for gold prices to increase in the next eight years.

Keywords: deep learning, forecasting, gold, hyperparameter, LSTM.



@Hak cipta milik IPB University

Hak Cipta Dilindungi Undang-undang

1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :
 - a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah
 - b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.
2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.

© Hak Cipta milik IPB, tahun 2023¹
Hak Cipta dilindungi Undang-Undang

Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan atau menyebutkan sumbernya. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik, atau tinjauan suatu masalah, dan pengutipan tersebut tidak merugikan kepentingan IPB.

Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apa pun tanpa izin IPB.

PENERAPAN *LONG SHORT-TERM MEMORY* UNTUK PERAMALAN HARGA EMAS

MUHAMMAD RIZKY NURHAMBALI

Skripsi
sebagai salah satu syarat untuk memperoleh gelar
Sarjana pada
Program Studi Statistika dan Sains Data

**DEPARTEMEN STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
INSTITUT PERTANIAN BOGOR
BOGOR
2023**



@Hak cipta milik IPB University

Hak Cipta Dilindungi Undang-undang

1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :
 - a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah
 - b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.
2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.

Tim Penguji pada Ujian Skripsi:
Akbar Rizki, S. Stat., M. Si.



Judul Skripsi : Penerapan *Long Short-Term Memory* untuk Peramalan Harga Emas
Nama : Muhammad Rizky Nurhambali
NIM : G14190022

Disetujui oleh

Pembimbing 1:

Dr. Yenni Angraini, S.Si., M.Si.

Pembimbing 2:

Dr. Anwar Fitrianto, S.Si., M.Sc.

Diketahui oleh

Ketua Departemen Statistika:

Dr. Bagus Sartono, S. Si., M. Si

NIP 19780411 200501 1 002

Tanggal Ujian:
19 Juni 2023

Tanggal Lulus:



@Hak cipta milik IPB University

Hak Cipta Dilindungi Undang-undang

1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :
 - a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah
 - b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.
2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.

PRAKATA

Puji dan syukur penulis panjatkan kepada Allah subhanaahu wa ta'ala atas segala karunia-Nya sehingga karya ilmiah ini berhasil diselesaikan. Tema yang dipilih dalam penelitian yang dilaksanakan sejak bulan Desember 2022 sampai bulan Juni 2023 ini ialah peramalan, dengan judul “Penerapan *Long Short-Term Memory* untuk Peramalan Harga Emas”.

Penulisan karya ilmiah ini tidak luput atas bantuan dan dukungan berbagai pihak sehingga karya ilmiah ini dapat terselesaikan dengan baik. Oleh karena itu, penulis mengucapkan terima kasih kepada:

1. Ibu Dr. Yenni Angraini, S.Si., M.Si. dan Bapak Dr. Anwar Fitrianto, S.Si., M.Sc. selaku komisi pembimbing yang telah membantu, membimbing, mengarahkan, dan mendukung selama penyusunan karya ilmiah ini;
2. Ibu Akbar Rizki, S. Stat., M. Si. selaku dosen penguji luar yang telah memberikan saran dan masukan dalam penulisan karya ilmiah ini;
3. seluruh dosen dan tenaga pendidik Departemen Statistika yang telah memberi ilmu yang bermanfaat dan menunjang segala kebutuhan penulis selama perkuliahan dan penyusunan karya ilmiah ini;
4. Babe, Mama, adik Rizka, adik Riyan, dan keluarga besar penulis yang selalu memberikan doa, dukungan, dan kasih sayang kepada penulis;
5. teman-teman Statistika 56 dan sahabat-sahabat penulis yang senantiasa mendukung dan membersamai penulis dalam penyusunan karya ilmiah ini; dan
6. seluruh pihak yang telah membantu penulis dalam penyusunan karya ilmiah ini yang tidak dapat penulis sebutkan satu persatu.

Penulis menyadari bahwa dalam penulisan karya ilmiah ini masih banyak kekurangan. Penulis berharap karya ilmiah ini bermanfaat bagi pihak yang membutuhkan dan bagi kemajuan ilmu pengetahuan.

Bogor, Juli 2023

Muhammad Rizky Nurhambali



@Hak cipta milik IPB University

Hak Cipta Dilindungi Undang-undang

1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :
 - a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah
 - b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.
2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.



DAFTAR ISI

DAFTAR TABEL	x
DAFTAR GAMBAR	x
DAFTAR LAMPIRAN	x
I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Tujuan	2
II TINJAUAN PUSTAKA	3
2.1 <i>Long Short-Term Memory</i>	3
2.2 <i>Walk Forward Validation</i>	5
2.3 Ukuran Akurasi	5
III METODE	7
3.1 Data	7
3.2 Prosedur Analisis Data	7
3.3 Lingkungan Pengembangan	11
IV HASIL DAN PEMBAHASAN	12
4.1 Praproses dan Eksplorasi Data	12
4.2 Kestasioneran Data	13
4.3 Evaluasi Model LSTM Hasil <i>Walk Forward Validation</i>	13
4.4 Validasi Model LSTM	16
4.5 Peramalan	17
V SIMPULAN DAN SARAN	19
5.1 Simpulan	19
5.2 Saran	19
DAFTAR PUSTAKA	20
LAMPIRAN	24
RIWAYAT HIDUP	32



DAFTAR TABEL

1	Klasifikasi nilai MAPE oleh Lewis (1982)	6
2	Pembentukan sampel <i>walk forward validation</i>	8
3	Contoh kombinasi skenario pergeseran jendela tahunan dengan <i>hyperparameter</i> LSTM	10
4	Perbandingan <i>hyperparameter</i> terbaik setiap skenario pergeseran jendela	15
5	Evaluasi model <i>hyperparameter</i> terbaik dengan penggunaan <i>early stopping</i>	16
6	Perbandingan MAPE antarmodel hasil validasi	17

DAFTAR GAMBAR

1	Contoh arsitektur LSTM	3
2	Ilustrasi <i>walk forward validation</i>	5
3	Ilustrasi <i>walk forward validation</i> dengan skenario pergeseran jendela secara tahunan	8
4	Sampel <i>walk forward validation</i> skenario pergeseran jendela tahunan	9
5	Harga emas periode 2003-2023	12
6	Plot ACF (a) dan plot <i>Box-Cox</i> (b)	13
7	Rataan RMSE hasil kombinasi <i>hyperparameter</i> untuk setiap skenario pergeseran jendela	14
8	Evaluasi model terbaik sampel skenario pergeseran jendela tahunan (<i>optimizer RMSProp</i> , <i>learning rate</i> 0,01, dan <i>epoch</i> 500)	15
9	Hasil validasi Model 1 (a) dan Model 7 (b)	17
10	Hasil ramalan dengan Model 7	18

DAFTAR LAMPIRAN

1	Sampel <i>walk forward validation</i> skenario pergeseran jendela semester	25
2	Sampel <i>walk forward validation</i> skenario pergeseran jendela kuartal	26
3	Nilai rata-rata RMSE hasil kombinasi <i>hyperparameter</i> untuk setiap skenario pergeseran jendela	27
4	<i>Boxplot</i> RMSE hasil kombinasi <i>hyperparameter</i> untuk setiap skenario pergeseran jendela	28
5	Evaluasi model terbaik sampel skenario pergeseran jendela semester (<i>optimizer adam</i> , <i>learning rate</i> 0,001, dan <i>epoch</i> 100)	30
6	Evaluasi model dengan penyesuaian <i>learning rate</i> dan penggunaan <i>early stopping</i>	31

I PENDAHULUAN

1.1 Latar Belakang

Peramalan merupakan salah satu cara memperoleh informasi di masa depan dengan memanfaatkan informasi di masa lampau (Hyndman dan Athanasopoulos 2021). Saat ini, peramalan banyak berkembang, tidak hanya menggunakan metode klasik, seperti pemulusan (*smoothing*) atau *autoregressive integrated moving average* (ARIMA), tetapi dapat menggunakan *deep learning*. *Deep learning* menggunakan pembelajaran mendalam dan konsep *end-to-end* (Patterson dan Gibson 2017). Keberadaan *layer* atau lapisan pembelajaran dalam *deep learning* membuat akurasi dan performa *deep learning* lebih baik dibandingkan dengan algoritma lain (Nabipour *et al.* 2020; Qasem *et al.* 2020).

Salah satu metode *deep learning* yang biasa digunakan untuk peramalan adalah *long short-term memory* (LSTM). LSTM merupakan pengembangan salah satu jaringan syaraf (*neural network*), yaitu *recurrent neural network* (RNN). LSTM memiliki *hyperparameter* yang dapat menentukan tingkat keandalan dan performa kinerja model (Rijn dan Hutter 2018). *Hyperparameter* yang biasa digunakan dalam LSTM antara lain *learning rate*, *epoch*, dan *optimizer*. LSTM sering digunakan untuk peramalan data deret waktu karena dinilai lebih unggul dan andal dalam meramalkan periode jangka panjang dibandingkan algoritma lain (Zahara *et al.* 2019; Abbasimehr *et al.* 2020). Hal tersebut didukung penelitian Adhinata dan Rakhmadani (2021), serta Bodapati *et al.* (2020) yang melakukan peramalan dengan data Covid-19 menunjukkan LSTM cukup berhasil dalam meminimalkan kesalahan pada data yang berfluktuasi. Namun, meskipun suatu metode dikatakan baik, evaluasi tetap penting dilakukan untuk melihat keakuratan, seperti dengan penggunaan validasi silang (*cross validation*) deret waktu yang akan membagi data menjadi data latih dan data uji dengan memperhatikan urutan waktu (Liu dan Yang 2020). Menurut Khalid *et al.* (2021), jenis validasi silang yang dapat digunakan untuk menghindari kesalahan dalam peramalan adalah *rolling window cross validation* atau yang biasa disebut *walk forward validation*.

Hasil peramalan banyak digunakan untuk pembuatan keputusan dan perencanaan di masa depan, salah satunya dalam melakukan investasi. Investasi merupakan pengelolaan finansial maupun non-finansial dengan tujuan mendapat keuntungan di masa depan. Salah satu jenis investasi yang cukup populer adalah emas (Kurniawan 2019). Emas atau logam mulia merupakan komoditas tradisional yang digunakan sejak zaman dahulu dan diterima oleh seluruh dunia. Emas sebagai barang investasi dapat berbentuk perhiasan, batangan, maupun koin. Namun, penggunaan emas batangan lebih disarankan untuk investasi karena adanya sertifikat resmi yang dapat meminimalkan risiko pemalsuan dan tidak membutuhkan biaya produksi (Ahsanah 2022).

Investasi emas merupakan investasi yang mudah karena dapat dilakukan oleh semua orang tanpa melihat tingkat penghasilan maupun kedudukan seseorang (Akmal 2022). Menurut Puspitasari *et al.* (2022), emas disebut sebagai aset *safe haven*, yaitu aset yang dianggap memiliki nilai yang terus meningkat atau tetap meskipun kondisi pasar tidak stabil. Harga emas yang naik akan mendorong investor untuk memilih berinvestasi di emas daripada di pasar modal karena dengan risiko yang relatif lebih rendah, emas dapat memberikan hasil imbal balik yang baik

dengan kenaikan harganya (Fairuzie *et al.* 2022). Stabilitas harga emas dibuktikan pada saat krisis keuangan global 2008-2009 di mana banyak harga komoditas yang turun sekitar 40%, tetapi harga emas global cenderung naik rata-rata 6% (Szczygielski *et al.* 2018).

Data harga emas merupakan data deret waktu karena tersusun atas rangkaian informasi yang dicatat selama kurun waktu tertentu sehingga data ini memungkinkan untuk dilakukan peramalan. Peramalan harga emas dengan metode LSTM sebelumnya pernah dilakukan oleh Vidya dan Hari (2020). Penelitian tersebut menunjukkan metode LSTM lebih baik dibandingkan dengan metode ARIMA, estimasi matriks ragam peragam, *deep regression*, *support vector regression*, dan *convolutional neural network* (CNN) untuk data harga emas periode 2 Januari 1979 sampai dengan 31 Juli 2020. Penelitian lainnya oleh Yurtsever (2021) dengan data emas multivariat periode 2001 – 2021 juga menunjukkan penggunaan LSTM lebih baik dibandingkan *bidirectional-LSTM* dan *gated recurrent unit* (GRU). Namun, di antara kedua penelitian tersebut belum menggunakan validasi silang sehingga pada penelitian ini akan diterapkan kombinasi *hyperparameter* LSTM dengan *walk forward validation* dalam melakukan peramalan harga emas.

1.2 Rumusan Masalah

Berdasarkan latar belakang penelitian, rumusan masalah yang perlu dikaji adalah sebagai berikut.

- Bagaimana pengaruh *walk forward validation* terhadap penentuan *hyperparameter* LSTM?
- Bagaimana kombinasi *hyperparameter* terbaik LSTM untuk melakukan peramalan harga emas?
- Bagaimana hasil peramalan harga emas dengan kombinasi *hyperparameter* terbaik LSTM?


1.3 Tujuan

Penelitian ini bertujuan untuk melihat pengaruh *walk forward validation*, mendapatkan kombinasi *hyperparameter* terbaik LSTM, dan melakukan peramalan harga emas di masa depan dengan kombinasi *hyperparameter* terbaik yang didapat. Model LSTM diterapkan pada penelitian harga emas karena telah terbukti menjadi salah satu algoritma yang unggul dalam melakukan peramalan. Hal tersebut diharapkan dapat membantu para investor dalam menentukan strategi investasi yang akan dilakukan.

II TINJAUAN PUSTAKA

2.1 Long Short-Term Memory

Long short-term memory (LSTM) merupakan sebuah metode pengembangan jaringan syaraf jenis *recurrent neural network* (RNN) yang diperkenalkan pertama kali oleh Hochreiter dan Schmidhuber pada tahun 1997. Hal yang menjadi pengembangan RNN pada LSTM terletak pada mekanisme gerbang (*gate*) khusus dalam mengontrol akses sel memori. Sel memori sebagai tempat penyimpanan informasi akan mendapatkan informasi yang terseleksi oleh mekanisme gerbang (Hochreiter dan Schmidhuber 1997 dalam Manowska 2020). Menurut Kalchbrenner *et al.* (2016), secara spesifik, mekanisme gerbang dalam LSTM tersusun atas tiga unit gerbang vektor, yaitu *input gate*, *forget gate*, dan *output gate*. Masing-masing unit gerbang vektor memiliki fungsi yang berbeda. Gerbang vektor *input* berfungsi untuk mengendalikan jumlah vektor masukan yang akan mempengaruhi memori. Gerbang vektor *forget* berfungsi untuk mengendalikan jumlah memori lama yang akan dihapus. Gerbang vektor *output* berfungsi untuk mengendalikan banyak memori yang disimpan dalam *hidden state*.



Gambar 1 Contoh arsitektur LSTM (Mahjoub *et al.* 2022)

Keterangan:

- x_t = nilai masukan waktu ke- t
- h_t = nilai keluaran waktu ke- t
- c_{t-1}, c_t = *cell state* waktu ke- $(t-1)$ dan t

LSTM memiliki beberapa tahapan umum di dalamnya (Gambar 1). Masing-masing gerbang memiliki vektor aktivasi yang akan mengolah nilai x_t dan h_{t-1} dengan fungsi aktivasi *sigmoid* yang menghasilkan nilai x di rentang 0 sampai 1 dan/atau fungsi aktivasi *tanh* yang menghasilkan nilai x di rentang -1 sampai 1. Berdasarkan Sarangapani (2006), rumus fungsi aktivasi *tanh* dan *sigmoid* secara berurutan dapat dilihat pada persamaan (1) dan (2).

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (1)$$

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (2)$$

Di mana x adalah nilai masukan dan e adalah nilai eksponensial.

Selain itu, terdapat matriks pembobot (\mathbf{W}) dan parameter vektor bias (\mathbf{b}) pada masing-masing gerbang yang akan dipelajari selama pelatihan. Menurut Goyal *et al.* (2018), tahapan pertama diawali dengan menentukan informasi yang akan dihapus oleh blok sel memori pada *forget gate* (\mathbf{f}_t) dengan fungsi aktivasi *sigmoid* mengikuti persamaan (3).

$$\mathbf{f}_t = \sigma(\mathbf{W}_f \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f) \quad (3)$$

Tahapan kedua yaitu menentukan informasi yang akan disimpan dalam *cell state*. Tahap ini terdiri dari dua bagian, pertama adalah pembaruan nilai oleh *input gate* (\mathbf{i}_t) dengan fungsi aktivasi *sigmoid* sebagaimana persamaan (4) dan kedua adalah pembuatan vektor kandidat nilai baru ($\tilde{\mathbf{c}}_t$) dengan fungsi aktivasi *tanh* mengikuti persamaan (5).

$$\mathbf{i}_t = \sigma(\mathbf{W}_i \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i) \quad (4)$$

$$\tilde{\mathbf{c}}_t = \tanh(\mathbf{W}_c \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_c) \quad (5)$$

Tahap ketiga merupakan pembaruan *cell state* lama ke dalam *cell state* baru mengikuti persamaan (6).

$$\mathbf{c}_t = \mathbf{f}_t \times \mathbf{c}_{t-1} + \mathbf{i}_t \times \tilde{\mathbf{c}}_t \quad (6)$$

Tahap terakhir dalam LSTM adalah penentuan keluaran oleh *output gate* (\mathbf{o}_t) dengan mengikuti persamaan (7) yang didasarkan pada hasil pembaruan *cell state* menggunakan fungsi aktivasi *sigmoid*. Hasil persamaan (7) kemudian akan dikombinasikan dengan fungsi aktivasi *tanh* untuk menghasilkan keluaran \mathbf{h}_t sebagaimana ditunjukkan oleh persamaan (8).

$$\mathbf{o}_t = \sigma(\mathbf{W}_o \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o) \quad (7)$$


$$\mathbf{h}_t = \mathbf{o}_t \times \tanh(\mathbf{c}_t) \quad (8)$$

Selain adanya mekanisme gerbang, proses pemodelan LSTM dapat dibentuk menggunakan beberapa *hyperparameter*. *Hyperparameter* adalah elemen dalam *deep learning* yang tidak diperbarui selama proses pelatihan, tetapi dapat memengaruhi akurasi algoritma (Han *et al.* 2020). *Hyperparameter* LSTM yang biasa digunakan antara lain *learning rate* dan *epoch*. *Learning rate* berfungsi mengontrol perubahan bobot yang diperbarui selama proses latih, sementara *epoch* sebagai penunjuk jumlah algoritma yang dijalankan untuk keseluruhan data (Aristyanto dan Kurniawan 2021; Brownlee 2022). Namun, masih terdapat *hyperparameter* lain yang dapat digunakan, yaitu *optimizer*. *Optimizer* adalah metode optimisasi untuk meningkatkan akurasi dalam model pembelajaran mesin. Jenis *optimizer* yang umum digunakan dalam LSTM antara lain *adaptive*

momentum (adam) dan *root mean square propagation (RMSProp)*. *Adam* merupakan metode optimisasi gradien-stokastik bebas yang dibangun oleh Kingma dan Ba (2014). *Adam* menentukan ukuran langkah dan *learning rate* secara stokastik menggunakan pengambilan sampel acak dari distribusi peluang, sedangkan *RMSProp* adalah teknik untuk mengurangi *noise* pada *neural network* dengan menghaluskan kesalahan saat disebarkan melalui jaringan (Mehmood *et al.* 2023). *RMSProp* menangani masalah gradien menghilang dengan menggunakan rata-rata bergerak gradien kuadrat untuk menormalkan gradien. Normalisasi ini menyeimbangkan ukuran langkah (momentum), mengurangi langkah untuk gradien besar agar tidak meledak dan meningkatkan langkah untuk gradien kecil agar tidak menghilang (Sanghvi 2021).

2.2 Walk Forward Validation

Walk forward validation adalah jenis metode paling umum dari *backtesting cross validation*, yaitu bentuk metode validasi silang deret waktu untuk mengukur kebaikan strategi atau model yang umumnya menggunakan amatan di masa lampau tanpa ada pelatihan ulang (*retraining*). *Walk forward validation* menggunakan pergeseran jendela di dalam dan di luar sampel data secara konstan (Gambar 2). Jendela adalah bagian yang memuat keseluruhan dari data latih dan data uji. Ukuran data pelatihan, data pengujian, dan pergeseran jendela dipertahankan sama sehingga dihasilkan beberapa pasangan pelatihan-pengujian (Prado 2018).



Gambar 2 Ilustrasi *walk forward validation* (dimodifikasi dari Khalid *et al.* (2021))

2.3 Ukuran Akurasi

Akurasi menjadi salah satu ukuran yang penting dalam menentukan kebaikan model. Akurasi ramalan hanya dapat ditentukan dengan mempertimbangkan seberapa baik kinerja model pada data baru yang tidak digunakan saat pembentukan model (Hyndman dan Athanasopoulos 2021). Ukuran akurasi yang umumnya digunakan untuk peramalan antara lain *root mean square error* (RMSE) dan *mean absolute percentage error* (MAPE). RMSE adalah metode evaluasi model dengan menghitung nilai rata-rata dari jumlah kuadrat kesalahan. Nilai RMSE yang rendah menunjukkan bahwa akurasi semakin baik dengan keragaman nilai yang dihasilkan model mendekati keragaman nilai aslinya (Herwanto *et al.* 2019). MAPE adalah

ukuran akurasi yang menghitung perbedaan antara data aktual dan data perkiraan dalam bentuk persentase (Yulian *et al.* 2020). Nilai RMSE dan MAPE menurut Poon (2005) secara berurutan dapat dihitung menggunakan persamaan (9) dan (10) dan klasifikasi nilai MAPE menurut Lewis (1982) yang ditunjukkan oleh Tabel 1.

$$RMSE = \sum_{t=1}^n \left(\frac{(x_t - \hat{x}_t)^2}{n} \right)^{\frac{1}{2}} \quad (9)$$

$$MAPE = \frac{1}{n} \sum_{t=1}^n \left| \frac{x_t - \hat{x}_t}{x_t} \right| \times 100\% \quad (10)$$

Keterangan:

- x_t = nilai waktu ke- t
- \hat{x}_t = nilai ramalan waktu ke- t
- n = jumlah periode peramalan

Tabel 1 Klasifikasi nilai MAPE oleh Lewis (1982)

MAPE (%)	Kemampuan Peramalan
<10	Sangat baik
10-20	Baik
20-50	Cukup baik
>50	Lemah

III METODE

3.1 Data

Data yang digunakan merupakan data sekunder harga emas harian yang berasal dari *World Gold Council*. Data emas tersebut merupakan data harian untuk lima hari kerja (Senin – Jumat). Data ini terdiri dari 5.233 data dengan periode yang digunakan adalah 1 Januari 2003 sampai dengan 20 Januari 2023. Data diperoleh melalui situs <https://www.gold.org/goldhub/data/gold-prices>.

3.2 Prosedur Analisis Data

Tahapan-tahapan analisis yang dilakukan pada penelitian ini adalah sebagai berikut.

a. Melakukan praproses data.

Praproses data dilakukan dengan melihat dan mengubah tipe data masukan agar sesuai dengan bahasa pemrograman aplikasi dan melakukan imputasi data. Data emas yang digunakan pada penelitian ini merupakan data harian pada hari kerja sehingga perlu dilakukan imputasi untuk mengisi nilai data pada akhir pekan dan hari libur. Metode imputasi yang akan digunakan adalah interpolasi linear. Menurut Chapra (2012), interpolasi linear adalah interpolasi untuk memperkirakan nilai dari dua buah nilai yang diketahui. Rumus interpolasi linear dapat dilihat pada persamaan (11).

$$f_1(x) = f(x_1) + \frac{f(x_2) - f(x_1)}{(x_2 - x_1)}(x - x_1) \quad (11)$$

Keterangan:

x_1	= periode waktu sebelum data hilang	$f(x_1)$	= nilai data satu periode sebelum data hilang
x_2	= periode waktu setelah data hilang	$f(x_2)$	= nilai data satu periode setelah data hilang
x	= periode waktu dari data hilang	$f_1(x)$	= nilai data hilang yang akan diimputasi

b. Melakukan eksplorasi data untuk memahami dan mendapatkan karakteristik data, serta melakukan evaluasi terhadap plot *autocorrelation function* (ACF) dan plot *Box-Cox* untuk melihat kestasioneran data. Data dikatakan stasioner jika plot ACF turun secara cepat dan memiliki nilai *rounded value* (λ) sama dengan satu atau nilai satu berada pada selang kepercayaan plot *Box-Cox* (Wahyuningsih *et al.* 2019).

c. Membuat skenario *walk forward validation*.

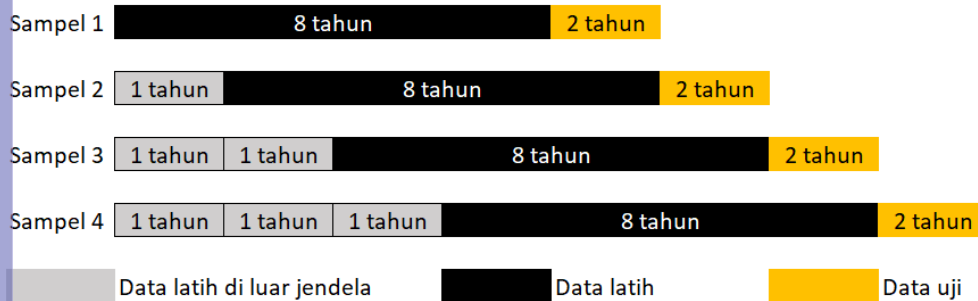
Walk forward validation diawali dengan pembuatan sampel. Sampel dari *walk forward validation* diperoleh dengan menentukan terlebih dahulu panjang data latih, data uji, dan jarak pergeseran jendela. Panjang untuk kedua data dan jarak pergeseran ditentukan secara subjektif dengan rincian tertera pada Tabel 2 sebagai bentuk penyesuaian fungsi dalam aplikasi pengolahan data.

Tabel 2 Pembentukan sampel *walk forward validation*

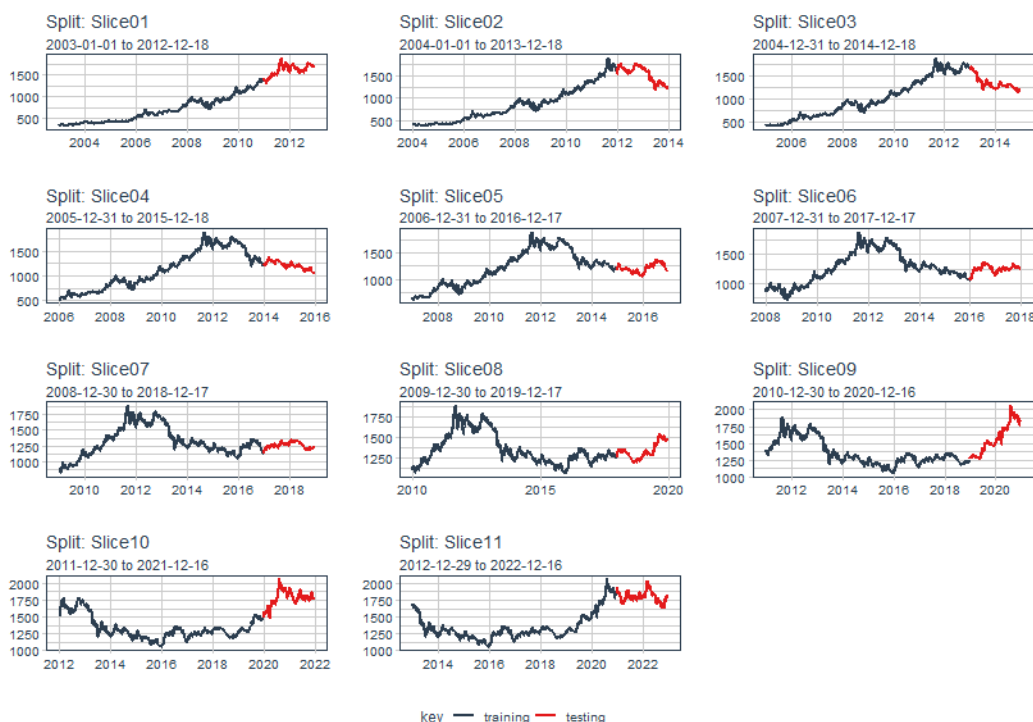
Skenario	Panjang Data Latih	Panjang Data Uji	Jarak Pergeseran	Jumlah Sampel
Tahunan			7×52	11
Semester	7×52×8	7×52×2	7×26	21
Kuartal			7×13	41

@Hak cipta milik IPB University

Tabel 2 menunjukkan setiap skenario memiliki panjang data latih dan data uji yang sama, yaitu sebanyak delapan tahun untuk data latih dan dua tahun untuk data uji. Namun, ketiganya berbeda dalam jarak pergeseran. Angka pada kolom ke-2, ke-3, dan ke-4 secara berurutan menunjukkan jumlah hari, jumlah minggu, dan jumlah tahun. Jumlah data yang digunakan dalam pembuatan data latih dan data uji sebanyak sepuluh tahun memungkinkan pergeseran sampel jendela dengan irisan data sebanyak jarak pergeseran di setiap sampelnya. Selain menyebabkan irisan, jarak pergeseran jendela yang merupakan representasi dari skenario juga mengakibatkan jumlah sampel yang berbeda. Ilustrasi strategi pergeseran jendela ditunjukkan oleh Gambar 3 dengan pergeseran jendela tahunan di mana data latih di luar jendela pada sampel setelahnya akan bertambah satu tahun sesuai skenario yang digunakan. Hasil akhir sampel yang terbentuk ditunjukkan oleh Gambar 4. Hal tersebut juga berlaku untuk skenario pergeseran jendela semester dan kuartal dengan hasil akhir sampel secara berurutan ditunjukkan oleh Lampiran 1 dan Lampiran 2.



Gambar 3 Ilustrasi *walk forward validation* dengan skenario pergeseran jendela secara tahunan



Gambar 4 Sampel *walk forward validation* skenario pergeseran jendela tahunan

d. Melakukan pemodelan dengan LSTM untuk satu sampel *walk forward validation*.

- 1) Sebelum melakukan pemodelan, dilakukan praproses berupa penggabungan data latih dan data uji hasil poin (c). Selanjutnya, melakukan standardisasi data karena LSTM bekerja lebih baik dengan data yang sudah dipusatkan dan diskalakan (Khan *et al.* 2020). Standardisasi akan menyebabkan data memiliki rata-rata nol dan ragam bernilai satu. Menurut Schuller (2017) standardisasi dilakukan mengikuti persamaan (12).

$$x_t^* = \frac{x_t - \bar{x}}{\sigma_x} \quad (12)$$

Di mana x_t^* adalah nilai masukan ke- t hasil standardisasi, x_t adalah nilai masukan ke- t , \bar{x} adalah nilai rata-rata data, dan σ_x adalah simpangan baku x .

- 2) Melakukan inisialisasi *hyperparameter* LSTM yang akan diproses.

Mengacu pada penelitian Alhamdani (2021) dan Yurtsever (2021), nilai *learning rate* yang akan digunakan antara lain 0,01; 0,001; dan 0,0001; serta *epoch* dengan nilai 100, 500, dan 1000. Selain itu, digunakan *optimizer adam* dan *RMSPprop*. Seluruh *hyperparameter* kemudian dikombinasikan dengan skenario pergeseran jendela. Setiap skenario pergeseran jendela akan mendapatkan 18 kombinasi *hyperparameter*, seperti yang ditunjukkan dalam Tabel 3 untuk skenario pergeseran jendela tahunan. Hal tersebut juga berlaku untuk skenario pergeseran semester dan kuartal sehingga total kombinasi yang dihasilkan adalah sebanyak 54 kombinasi. Namun,

arsitektur dan *hyperparameter* lain dalam LSTM ditentukan mengikuti prosedur analisis data yang berjalan.

Tabel 3 Contoh kombinasi skenario pergeseran jendela tahunan dengan *hyperparameter* LSTM

Nomor	Skenario Pergeseran Jendela	Hyperparameter		
		Optimizer	Learning Rate	Epoch
1.	Tahunan	Adam	0,01	100
2.				500
3.				1000
4.			0,001	100
5.				500
6.				1000
7.				100
8.			0,0001	500
9.				1000
10.				100
11.		RMSProp	0,01	500
12.				1000
13.				100
14.			0,001	500
15.				1000
16.				100
17.			0,0001	500
18.				1000

- 3) Melakukan pelatihan dan *fit* model LSTM untuk satu sampel *walk forward validation*.
- 4) Melakukan evaluasi model dengan RMSE.
- e. Mengulang langkah (d) untuk semua sampel dari masing-masing skenario pergeseran jendela.
- f. Menghitung nilai rata-rata RMSE dari tiap kombinasi *hyperparameter* untuk setiap skenario pergeseran jendela dan mengambil *hyperparameter* terbaik.
- g. Melakukan penanganan masalah *underfitting* dan *overfitting* yang sering dijumpai dalam penggunaan LSTM dengan *early stopping*. *Early stopping* akan menghentikan proses lebih cepat ketika terjadi penurunan validasi dan mempertahankan kondisi optimal tanpa perlu menjalankan keseluruhan *epoch* (Liang dan Cai 2020; Almousa *et al.* 2022).
- h. Melakukan validasi dari kombinasi *hyperparameter* terbaik pada poin (f) untuk keseluruhan data dan menghitung nilai MAPE. Masing-masing *hyperparameter* pada poin (f) dikombinasikan kembali untuk melihat kemungkinan kombinasi *hyperparameter* lain yang menghasilkan ramalan terbaik di luar kombinasi hasil poin (f). Pada langkah ini, seluruh data akan kembali dibagi menjadi data latih dan data uji dengan menggunakan proporsi yang mengacu pada pola data.

- i. Melakukan peramalan dengan keseluruhan data dengan *hyperparameter* terbaik poin (h) yang memiliki nilai MAPE terkecil.

3.3 Lingkungan Pengembangan

Spesifikasi perangkat keras dan perangkat lunak yang digunakan adalah sebagai berikut.

- a. Perangkat keras berupa komputer dan laptop dengan spesifikasi:
 - 1) *processor* Intel® Core™ i7-1165G7 @ 2,80 GHZ (komputer) dan AMD Ryzen 7 4700U dengan Radeon Graphics 2.00 GHz (laptop); serta
 - 2) *random access memory* 8 GB.
- b. Perangkat lunak yang digunakan dalam penelitian ini antara lain:
 - 1) sistem operasi Windows 10 Pro (komputer), Windows 11 Pro (komputer), dan Windows 11 Home Single Language (laptop);
 - 2) R versi 4.2.2 dan 4.3.0, serta RStudio sebagai *integrated development environment* (IDE);
 - 3) Python versi 3.11 untuk pemodelan LSTM yang terintegrasi kepada R; dan
 - 4) *library packages keras* dan *tensorflow*.





IV HASIL DAN PEMBAHASAN

4.1 Praproses dan Eksplorasi Data

Praproses data dalam penelitian ini diawali dengan pengubahan format data. Format data untuk peubah tanggal yang sebelumnya bertipe *POSIXtc* dikonversi menjadi *datetime* sehingga peubah tanggal dapat terbaca dan diolah sesuai dengan tipe datanya dengan bahasa pemrograman R. Selanjutnya, praproses data yang dilakukan adalah melakukan imputasi data untuk nilai pada peubah harga di akhir pekan (Sabtu-Minggu) dan hari libur dengan interpolasi linear. Jumlah data yang sebelumnya terdiri atas 5.233 data, bertambah menjadi 7.325 data setelah dilakukan imputasi.

Setelah praproses data, dilakukan eksplorasi data. Eksplorasi data diawali dengan melihat statistik deskriptif data dan diperoleh rata-rata harga emas harian sebesar 1.161,9 US\$/troi ons dengan penyebaran sebesar (simpangan baku) 462,399 dari rata-rata. Nilai simpangan baku yang cukup besar menunjukkan penyebaran data terhadap rata-rata juga besar sebagaimana dapat dilihat pada Gambar 5. Data harga emas tertinggi mencapai 2.067,2 US\$/troi ons pada tanggal 6 Agustus 2020 (titik hijau), sedangkan harga emas terendah menyentuh 319,9 US\$/troi ons pada tanggal 7 April 2003 (titik merah).




Gambar 5 Harga emas periode 2003-2023

Selain dengan statistik deskriptif, eksplorasi dilakukan dengan membuat plot deret waktu. Gambar 5 menunjukkan plot data deret waktu harga emas harian dengan sumbu x sebagai periode waktu dan sumbu y sebagai penunjuk harga emas per satuan troi ons dalam US\$. Gambar 5 menunjukkan bahwa data memiliki tren positif yang ekstrem di awal hingga akhir periode. Harga emas terlihat memiliki tren positif yang ekstrem sekitar tahun 2008 hingga pertengahan 2012. Hal ini disebabkan oleh krisis keuangan global sehingga investor lebih memilih berinvestasi pada emas sebagai aset yang dianggap aman. Kemudian, terlihat tren negatif di akhir 2012 hingga 2013 akibat pemulihan ekonomi dan berfluktuasi untuk periode selanjutnya hingga akhir 2019. Akan tetapi, fluktuasi ini masih menunjukkan kestabilan. Harga emas kemudian kembali mengalami kenaikan yang ekstrem di tahun 2020 hingga

pertengahan 2021. Lonjakan tertinggi harga emas harian terjadi pada pertengahan 2020. Hal tersebut diakibatkan oleh efek pandemi Covid-19 sehingga investor kembali beralih pada instrumen investasi yang stabil seperti emas. Setelah keadaan cukup membaik dan vaksinasi mulai tersebar, ekonomi global turut pulih sehingga investor beralih kembali untuk berinvestasi pada instrumen berisiko tinggi yang berdampak pada harga emas yang terlihat menurun. Namun, setelahnya harga emas masih stabil meskipun berfluktuasi.

4.2 Kestasioneran Data

Harga emas yang berfluktuasi seperti terlihat pada Gambar 5 mengindikasikan bahwa data tidak stasioner dalam rata-rata karena data tidak menyebar di sekitar nilai rata-rata. Gambar 6(a) menunjukkan plot ACF yang terlihat menurun secara perlahan dan berada di luar interval nilai galat bakunya (garis putus-putus biru). Oleh karena itu, bisa diidentifikasi bahwa data harga emas dunia tersebut tidak stasioner dalam rata-rata. Selain tidak stasioner dalam rata-rata, data harga emas juga diduga tidak stasioner dalam ragam karena terlihat melebar dan menyempit secara tidak seimbang. Gambar 6(b) menunjukkan nilai *rounded value* (λ) sebesar 0,8414 dan pada selang kepercayaan 95% nilai λ memiliki batas bawah 0,8051 dan batas atas 0,8778. Selang tersebut tidak memuat nilai satu sehingga dapat dikatakan bahwa data harga emas penutupan tidak stasioner dalam ragam.



Gambar 6 Plot ACF (a) dan plot *Box-Cox* (b)

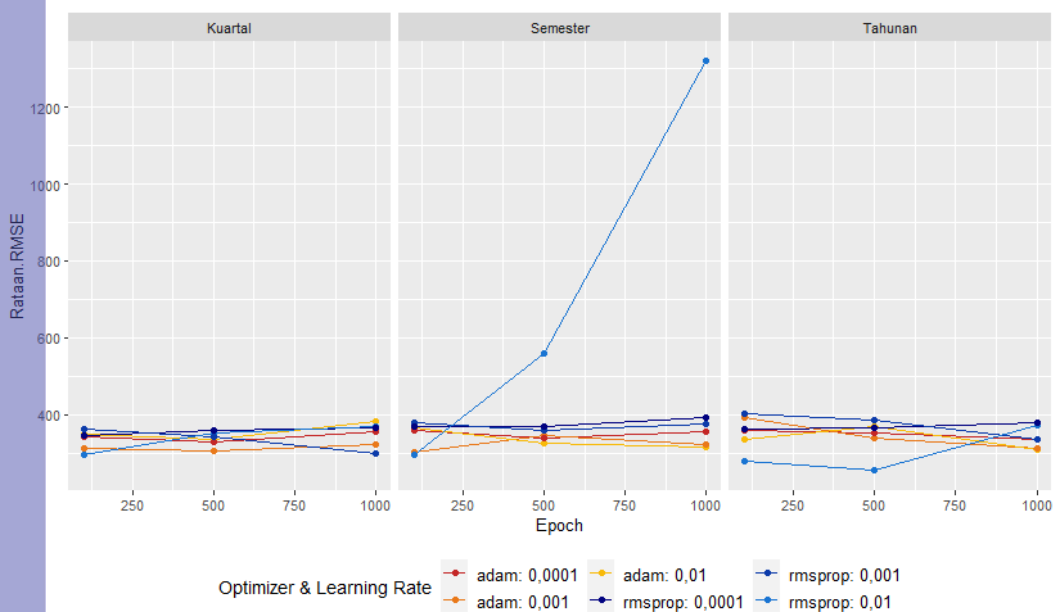
Menurut Lin dan Feng (2022), penggunaan metode *deep learning*, khususnya jaringan syaraf (*neural network*), tidak memerlukan asumsi kestasioneran karena dianggap mampu menangani hubungan nonlinear dan dimensi besar. Selain itu, Long *et al.* (2023) menyebutkan LSTM menjadi algoritma yang mampu mengatasi hambatan linearitas pada model *autoregressive-moving average* (ARMA) dan asumsi kestasioneran. Oleh karena itu, data harga emas yang tidak stasioner dalam rata-rata dan ragam, tidak perlu dilakukan penanganan.

4.3 Evaluasi Model LSTM Hasil *Walk Forward Validation*

Evaluasi model diawali dengan pembangunan model LSTM yang akan digunakan dalam pemrosesan data. LSTM dibangun dengan arsitektur berupa *layer* dan inisialisasi *hyperparameter* seperti *batch size*, *epoch*, dan *learning rate*. Selain nilai *epoch* dan *learning rate*, penelitian ini menginisialisasi *hyperparameter* secara acak berdasarkan percobaan. Model LSTM dibangun dengan dua *layer* LSTM

dengan masing-masing *layer* terdiri atas 50 unit neuron dan satu *dense layer*. *Optimizer* yang digunakan adalah *adam* dan *RMSProp*. Menurut Mehmood *et al.* (2023), *adam* disebut sebagai *optimizer* yang efisien, sementara *RMSProp* dianggap mampu lebih mengatasi *noise*. Selanjutnya, *batch size* ditentukan dengan mengambil faktor persekutuan dari jumlah data di antara data latih dan data uji. Pada penelitian ini *batch size* yang digunakan sebesar 56.

Evaluasi model diperoleh dari nilai rata-rata RMSE semua sampel pada setiap kombinasi model dengan skenario pergeseran jendela. Lampiran 3 menunjukkan perbedaan *hyperparameter* tidak membuat nilai rata-rata RMSE cenderung meningkat atau menurun karena kombinasi *hyperparameter* dengan skenario pergeseran jendela menghasilkan nilai rata-rata yang berbeda. Selang nilai RMSE pada Lampiran 4 menunjukkan penggunaan *hyperparameter* yang berbeda tidak memberikan pengaruh pada proses peramalan. Akan tetapi, hasil tersebut dapat menjadi pengecualian untuk kombinasi *optimizer RMSProp* dengan *learning rate* 0,001-*epoch* 500 dan *learning* 0,0001-*epoch* 1000 pada skenario semester karena nilai rata-rata RMSE yang cukup berbeda dibandingkan kombinasi lain seperti pada Gambar 7. Selain itu, Lampiran 4 menunjukkan penggunaan *epoch* 1000 pada setiap skenario pergeseran jendela menunjukkan keragaman nilai RMSE sampel yang lebih besar dibandingkan *epoch* 100 dan 500.



Gambar 7 Rataan RMSE hasil kombinasi *hyperparameter* untuk setiap skenario pergeseran jendela

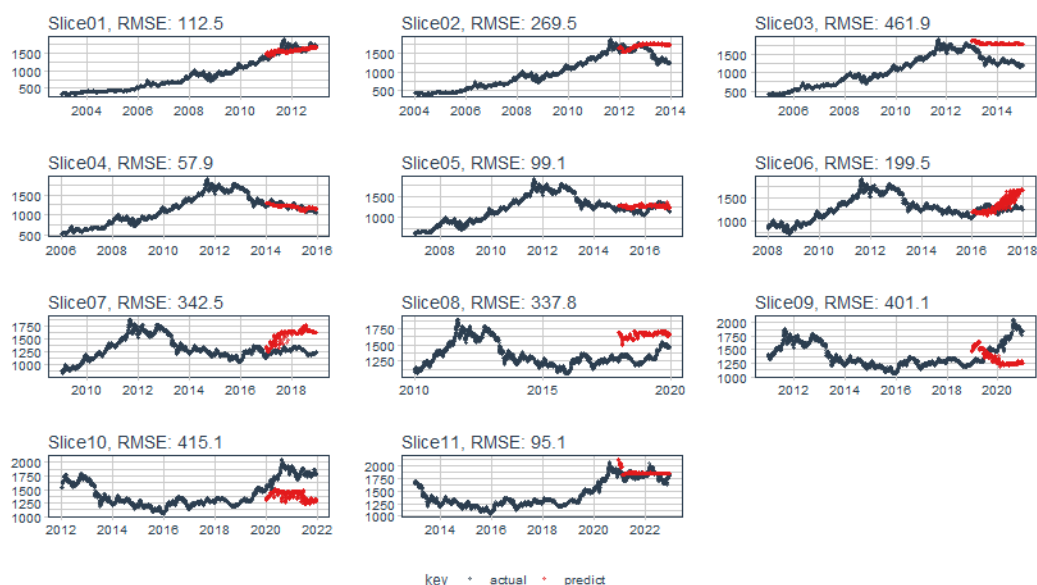
Gambar 7 menunjukkan penggunaan *optimizer RMSProp* dengan *learning rate* besar dan *epoch* kecil menghasilkan rata-rata RMSE yang lebih kecil, sementara *optimizer adam* menghasilkan nilai rata-rata RMSE lebih kecil dengan *learning rate* kecil. Namun, penggunaan *epoch* pada adam tidak menunjukkan suatu kecenderungan menaikkan atau menurunkan nilai rata-rata RMSE. Kedua hasil ini sesuai penelitian Guha (2023) dengan data MNIST dan CIFAR-10 untuk melihat pengaruh *learning rate* terhadap berbagai *optimizer*. Penelitian dengan data MNIST

menunjukkan *RMSProp* dan *adam* bekerja lebih baik dengan *learning rate* 0,01; 0,001; dan 0,003, serta penggunaan *epoch* pada *optimizer adam* menunjukkan akurasi yang cenderung stabil.

Nilai rata-rata RMSE dari masing-masing kombinasi *hyperparameter* dibandingkan untuk setiap skenario pergeseran jendela. Model terbaik adalah model dengan nilai RMSE terkecil sebagaimana ditunjukkan oleh Tabel 4. Evaluasi model LSTM dari ketiga skenario menunjukkan nilai *hyperparameter* yang berbeda dalam mendapatkan nilai RMSE yang terkecil. Kondisi ini menunjukkan pengaruh skenario pergeseran jendela akibat sampel yang terbentuk dalam masing-masing skenario. Penggunaan *optimizer RMSProp* cenderung menghasilkan rata-rata RMSE yang lebih kecil, tetapi nilai simpangan baku yang dihasilkan lebih besar dibandingkan dengan *optimizer adam*. Perbedaan nilai rata-rata dan simpangan baku RMSE dengan kombinasi *hyperparameter* ini dapat disebabkan keragaman nilai yang ada dalam sampel-sampel pada masing-masing skenario.

Tabel 4 Perbandingan *hyperparameter* terbaik setiap skenario pergeseran jendela

Skenario Pergeseran Jendela	Hyperparameter			RMSE	
	Optimizer	Learning Rate	Epoch	Rataan	Simpangan Baku
Tahunan	Adam	0,01	1000	309,279	134,0782
	RMSProp	0,01	500	253,817	147,1539
Semester	Adam	0,001	100	302,197	154,075
	RMSProp	0,01	100	294,349	171,5527
Kuartal	Adam	0,001	500	305,901	144,6814
	RMSProp	0,01	100	293,828	159,7856



Gambar 8 Evaluasi model terbaik sampel skenario pergeseran jendela tahunan (*optimizer RMSProp*, *learning rate* 0,01, dan *epoch* 500)

Gambar 8 dan Lampiran 5 menunjukkan banyak sampel tidak mengikuti plot data aslinya. Hal ini dapat berkaitan dengan adanya *underfitting* dan *overfitting*. *Underfitting* adalah kondisi ketika model tidak mampu mendapatkan nilai eror yang cukup rendah pada proses pelatihan sehingga kurang mewakili gambaran lengkap pola data, sementara itu *overfitting* adalah kondisi ketika model memiliki kinerja buruk pada data yang tidak terlihat, tetapi baik dalam proses pelatihan (Goodfellow *et al.* 2016; López *et al.* 2022). Mengikuti penelitian Liang dan Cai (2020) untuk tingkat standar pinjaman bulanan di *platform* pinjaman *peer-to-peer* (P2P) Amerika, masalah *underfitting* LSTM dapat ditangani dengan penyesuaian nilai *learning rate*. Nilai *learning rate* akan dilakukan penyesuaian secara acak dari nilai *learning rate* yang menghasilkan nilai RMSE terkecil. Selanjutnya, masalah *overfitting* LSTM dapat ditangani dengan penggunaan *early stopping*.

Tabel 5 Evaluasi model *hyperparameter* terbaik dengan penggunaan *early stopping*

Skenario Pergeseran Jendela	Hyperparameter			RMSE	
	Optimizer	Learning Rate	Epoch	Rataan	Simpangan Baku
Tahunan	Adam	0,01	1000	391,3207	107,3493
	RMSProp	0,01	500	283,0335	116,6134
Semester	Adam	0,001	100	297,9389	141,6134
	RMSProp	0,01	100	259,2762	137,2124
Kuartal	Adam	0,001	500	303,2841	148,0506
	RMSProp	0,01	100	286,8102	321,3874

Tabel 5 menunjukkan penggunaan *early stopping* dapat menurunkan nilai rata-rata RMSE skenario pergeseran jendela semester dan kuartal, serta menurunkan nilai simpangan baku skenario pergeseran jendela tahunan. Penggunaan *early stopping* yang berhasil kemudian dikombinasikan dengan penyesuaian *learning rate* secara acak di sekitar nilai terbaiknya. Hasil yang didapatkan adalah nilai rata-rata RMSE cenderung menghasilkan nilai yang acak dan lebih besar daripada *learning rate* optimum yang didapat (Lampiran 6). Nilai *learning rate* optimal yang sesuai inisialisasi awal sudah sejalan dengan pernyataan Goodfellow *et al.* (2016) yang menyatakan pencarian *learning rate* optimum melibatkan nilai dengan skala fungsi logaritmik (0,1; 0,01; 0,001; 0,0001; 0,00001). Oleh karena itu, nilai *hyperparameter* untuk model terbaik pada Tabel 4 akan tetap digunakan pada tahap validasi.

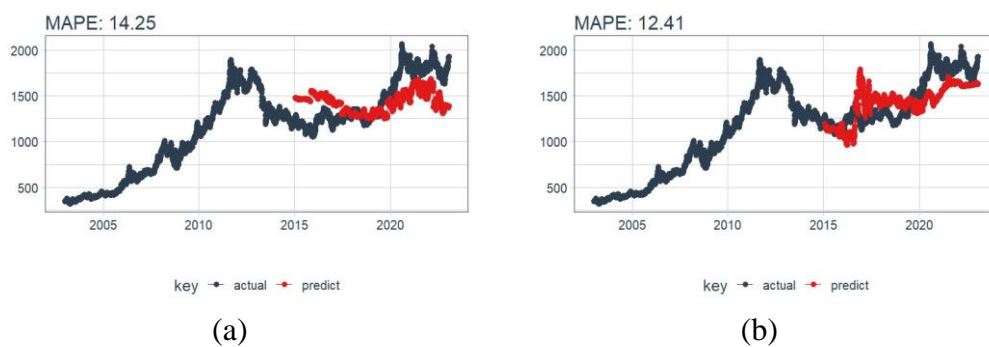
4.4 Validasi Model LSTM

Model terbaik LSTM dengan *hyperparameter* yang didapat kemudian divalidasi menggunakan keseluruhan data. Data kembali dibagi menjadi data latih dan data uji dengan perbandingan 60:40. Perbandingan tersebut dipilih karena terlihat pembagian data latih dan data uji yang memiliki kemiripan pola data dibandingkan dengan pembagian menggunakan nilai proporsi lainnya. Nilai *learning rate* dan *epoch* akan dikombinasikan berdasarkan *optimizer* untuk melihat ada tidaknya kombinasi lain di luar nilai Tabel 4 yang menghasilkan akurasi yang lebih baik. Masing-masing model yang terbentuk dihitung nilai MAPE untuk

melihat tingkat akurasi model yang tidak dapat diklasifikasikan dengan RMSE. Perbandingan nilai MAPE masing-masing kombinasi *hyperparameter* ditunjukkan oleh Tabel 6.

Tabel 6 Perbandingan MAPE antarmodel hasil validasi

Model	Optimizer	Learning Rate	Epoch	MAPE (%)
1	Adam	0,01	100	14,25
2	Adam	0,01	500	18,24
3	Adam	0,01	1000	18,83
4	Adam	0,001	100	22,06
5	Adam	0,001	500	26,94
6	Adam	0,001	1000	22,67
7	RMSProp	100	0,01	12,41
8	RMSProp	500	0,01	20,21




Gambar 9 Hasil validasi Model 1 (a) dan Model 7 (b)

Hasil validasi menunjukkan penggunaan *learning rate* 0,01 menghasilkan akurasi peramalan lebih baik dibandingkan *learning rate* 0,001 (Tabel 6). Hampir seluruh penggunaan *learning rate* 0,01 (kecuali Model 8) menghasilkan akurasi peramalan yang terklasifikasi peramalan baik menurut Tabel 1, sementara penggunaan *learning rate* 0,001 terklasifikasikan sebagai peramalan cukup baik. Hasil validasi Model 1 dan Model 7 menunjukkan hasil ramalan yang memiliki pola menyerupai pola data aslinya (Gambar 9). Hasil ini mengerucutkan model dengan penggunaan *learning rate* 0,01 dan *epoch* 100 menjadi kombinasi terbaik, sementara *optimizer* yang terbaik berdasarkan Tabel 6 adalah *RMSProp* karena Model 7 memiliki nilai terendah di antara semua penggunaan *optimizer Adam*. Model 7 menjadi model terbaik dengan nilai MAPE 12,41% dan terklasifikasikan sebagai peramalan baik.

4.5 Peramalan

Model terbaik hasil validasi, Model 7, digunakan untuk melakukan peramalan. Peramalan yang dimaksud adalah meramalkan nilai data setelah data terakhir. Pada penelitian ini data terakhir adalah tanggal 20 Januari 2023. Nilai data setelah tanggal 20 Januari 2023 akan diramalkan sampai 2.930 hari ke depan, sesuai jumlah

data uji pada proses validasi atau sekitar delapan tahun. Nilai peramalan menunjukkan harga emas yang diawali penurunan akan terus meningkat dalam jangka panjang (Gambar 10). Harga emas diramalkan meningkat sekitar 300 US\$/troi ons dalam delapan tahun dengan peningkatan cukup tajam terjadi antara tahun 2023 sampai 2025. Ramalan rata-rata harga emas pada tahun 2023 adalah sebesar 1.485,81 US\$/troi ons, tahun 2024 sebesar 1.687,35 US\$/troi ons, tahun 2025 sebesar 1.746,72 US\$/troi ons, tahun 2026 sebesar 1.762,73 US\$/troi ons, tahun 2027 sebesar 1.774,52 US\$/troi ons, tahun 2028 sebesar 1.790,17 US\$/troi ons, tahun 2029 sebesar 1.789,74 US\$/troi ons, tahun 2030 sebesar 1.792,22 US\$/troi ons, dan tahun 2031 sebesar 1.789,89 US\$/troi ons.



Gambar 10 Hasil ramalan dengan Model 7

Menurut *World Bank* (2023), harga emas tahun 2023, khususnya di kuartal pertama, akan meningkat akibat melemahnya dolar Amerika, meningkatnya ketegangan geopolitik dan tekanan inflasi, serta permintaan industri yang kuat untuk perak dan platinum. Namun, prediksi untuk tahun 2024, harga emas diprediksi menurun akibat pemulihan ekonomi global dan penurunan tekanan inflasi. Lebih lanjut lagi, dalam jangka panjang disebutkan inflasi dan nilai suku bunga menjadi faktor utama pergerakan harga emas, sementara volatilitas harga emas dalam jangka pendek kemungkinan akan berlanjut, mengingat ketidakpastian geopolitik dan ekonomi yang meningkat. Hasil peramalan yang peneliti lakukan berbeda dengan prediksi *World Bank* sehingga nilai hasil peramalan ini mungkin tidak seutuhnya benar dan sesuai. Namun, hasil ini masih sesuai dengan pernyataan Soelistijo *et al.* (2015) yang menyebutkan nilai emas akan terus menguat dalam jangka panjang. Emas mendapat tempat khusus dalam perdagangan dunia dan investasi akibat memiliki nilai yang tidak pernah tergerus oleh inflasi. Kondisi harga emas yang meningkat dapat dijadikan sebagai pilihan untuk menabung / berinvestasi, sementara itu pembelian emas dapat dilakukan saat dibutuhkan (Aswin dan Santhosh 2023).

V SIMPULAN DAN SARAN

5.1 Simpulan

Harga emas harian yang tidak stasioner dalam rata-rata dan ragam dapat dimodelkan dengan LSTM. Penggunaan skenario pergeseran jendela dalam proses *walk forward validation* memberikan pengaruh dalam penentuan *hyperparameter* yang berbeda di setiap skenario. Model LSTM terbaik yang didapat adalah hasil kombinasi *hyperparameter optimizer RMSProp*, *learning rate* 0,01, dan *epoch* 100. Model tersebut sudah dapat mengikuti pola nilai aktualnya dan menghasilkan akurasi nilai MAPE 12,41% pada proses validasi yang dapat diklasifikasikan memiliki peramalan baik. Hasil ramalan dengan model terbaik menunjukkan harga emas yang cenderung meningkat dalam delapan tahun mendatang. Kondisi harga emas yang meningkat dapat dimanfaatkan sebagai waktu yang tepat untuk berinvestasi.

5.2 Saran

Penelitian ini berfokus pada penerapan metode dengan data univariat yang masih mengabaikan asumsi peramalan statistik klasik. Penelitian lebih lanjut dapat menambahkan kovariat pada model dan penanganan pada pelanggaran asumsi, seperti masalah ketidakstasioneran data dapat dicobakan. Selain itu, metode LSTM dapat dikombinasikan dengan metode statistik klasik (ARIMA) maupun metode *deep learning* lain, seperti *artificial neural network*, CNN, atau GRU sebagai upaya pencarian model yang lebih baik.



DAFTAR PUSTAKA

- Abbasimehr H, Shabani M, Yousefi M. 2020. An optimized model using LSTM network for demand forecasting. *Computers & Industrial Engineering*. 143:1–13. doi:10.1016/J.CIE.2020.106435.
- Adhinata FD, Rakhmadani DP. 2021. Prediction of covid-19 daily case in Indonesia using long short term memory method. *Teknika*. 10(1):62–67. doi:10.34148/TEKNIKA.V10I1.328.
- Ahsanah DN. 2022. Emas sebagai instrumen investasi jangka panjang. *Shar-E : Jurnal Kajian Ekonomi Hukum Syariah*. 8(1):177–187. doi:10.37567/SHAR-E.V8I1.1297.
- Akmal RK. 2022. Tinjauan sistematis untuk merekomendasi prediksi harga emas. *Jurnal Inovasi Informatika*. 7(1):18–24. doi:10.51170/JII.V7I1.253.
- Alhamdani FDS. 2021. Prediksi harga emas menggunakan metode time series long short - term memory neural network [skripsi]. Malang: Universitas Muhammadiyah Malang. [diakses 2023 Jan 28]. <https://eprints.umm.ac.id/76096/>.
- Almousa M, Zhang T, Sarrafzadeh A, Anwar M. 2022. Phishing website detection: How effective are deep learning-based models and hyperparameter optimization? *Security and Privacy*. 5(6):1–19. doi:10.1002/SPY2.256.
- Aristyanto MY, Kurniawan R. 2021. Pengembangan metode neural machine translation berdasarkan hyperparameter neural network. Di dalam: *Seminar Nasional Official Statistics*. Volume ke-2021. Jakarta, Indonesia: Politeknik Statistika STIS. hlm 935–946.
- Aswin K, Santhosh T. 2023. The predictive analysis for economic development and financial status of India in 2023. *BOHR International Journal of Financial Market and Corporate Finance*. 2(1):10–16. doi:10.54646/bijfmc.013.
- Bodapati S, Bandarupally H, Trupthi M. 2020. Covid-19 time series forecasting of daily cases, deaths caused and recovered cases using long short term memory networks. Di dalam: Tsihrintzis GA, editor. *2020 IEEE 5th International Conference on Computing Communication and Automation, ICCCA 2020*. New Delhi, India: Institute of Electrical and Electronics Engineers Inc. hlm 525–530.
- Brownlee J. 2022. Difference Between a Batch and an Epoch in a Neural Network. *MachineLearningMastery.com.*, siap terbit. [diakses 2022 Des 7]. <https://machinelearningmastery.com/difference-between-a-batch-and-an-epoch/>.
- Chapra SC. 2012. *Applied Numerical Methods with MATLAB® for Engineers and Scientists*. Ed ke-3. New York (NY): McGraw-Hill.
- Fairuzie A, Siagian A, Stefhani Y. 2022. Analisis pengaruh earning per share, harga emas dunia, inflasi terhadap harga saham perusahaan sektor pertambangan di bursa efek indonesia pada masa pandemi covid-19. *Jurnal Manajemen*. 6(2):37–52. doi:10.54964/MANAJEMEN.V6I2.202.
- Goodfellow I, Bengio Y, Courville A. 2016. *Deep Learning*. Cambridge (MA): MIT Press.
- Goyal P, Pandey S, Jain K. 2018. *Deep Learning for Natural Language Processing: Creating Neural Networks with Python*. Berkeley (CA): Apress.

@Hak cipta milik IPB University

Hak Cipta Dilindungi Undang-undang
1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :
a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah
b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.
2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.

- Guha R. 2023. Benchmarking gradient based optimizers' sensitivity to learning rate. *SSRN Electronic Journal.*, siap terbit.
- Han JH, Choi DJ, Park SU, Hong SK. 2020. Hyperparameter optimization using a genetic algorithm considering verification time in a convolutional neural network. *Journal of Electrical Engineering & Technology.* 15(2):721–726. doi:10.1007/S42835-020-00343-7.
- Herwanto HW, Widiyaningtyas T, Indriana P. 2019. Penerapan algoritme linear regression untuk prediksi hasil panen tanaman padi. *Jurnal Nasional Teknik Elektro dan Teknologi Informasi.* 8(4):364–370. [diakses 2023 Jun 8]. <https://journal.ugm.ac.id/v3/JNTETI/article/view/2563>.
- Hyndman R, Athanasopoulos G. 2021. *Forecasting: Principles and Practice*. Ed ke-3. Melbourne: OTexts. [diakses 2023 Jun 10]. <https://otexts.com/fpp3/>.
- Kalchbrenner N, Danihelka I, Graves A. 2016. Grid long short-term memory. Di dalam: Bengio Y, LeCun Y, editor. *4th International Conference on Learning Representations, ICLR 2016 - Conference Track Proceedings*. San Juan, Puerto Rico: International Conference on Learning Representations, ICLR. hlm 1–15.
- Khalid W, Mahmood M, Avşar E. 2021. One step ahead prediction of ozone concentration for determination of outdoor air quality level. *MANAS Journal of Engineering.* 9(1):45–54. doi:10.51354/MJEN.869736.
- Khan P, Reddy BSK, Pandey A, Kumar S, Youssef M. 2020. Differential channel-state-information-based human activity recognition in IoT networks. *IEEE Internet of Things Journal.* 7(11):11290–11302. doi:10.1109/JIOT.2020.2997237.
- Kurniawan I. 2019. Analisis Keuntungan Investasi Emas Dengan Ihsg. *Jurnal Manajemen Bisnis dan Kewirausahaan.* 3(2):16–23. doi:10.24912/JMBK.V3I2.4955.
- Lewis CD. 1982. *Industrial and Business Forecasting Methods*. London: Butterworth Scientific.
- Liang L, Cai X. 2020. Forecasting peer-to-peer platform default rate with lstm neural network. *Electronic Commerce Research and Applications.* 43:1–10. doi:10.1016/J.ELERAP.2020.100997.
- Lin S, Feng Y. 2022. Research on stock price prediction based on orthogonal Gaussian basis function expansion and Pearson correlation coefficient weighted lstm neural network. *Advances in Computer, Signals and Systems.* 6(5):23–30. doi:10.23977/ACSS.2022.060504.
- Liu Z, Yang X. 2020. Cross validation for uncertain autoregressive model. *Communications in Statistics - Simulation and Computation.* 51(8):4715–4726. doi:10.1080/03610918.2020.1747077.
- Long B, Tan F, Newman M. 2023. Forecasting the monkeypox outbreak using arima, prophet, neuralprophet, and lstm models in the United States. *Forecasting.* 5(1):127–137. doi:10.3390/FORECAST5010005.
- López OAM, López AM, Crossa J. 2022. *Multivariate Statistical Machine Learning Methods for Genomic Prediction*. Cham: Springer International Publishing.
- Mahjoub S, Chrifi-Alaoui L, Marhic B, Delahoche L. 2022. Predicting energy consumption using LSTM, multi-layer GRU and drop-GRU neural networks. *Sensors.* 22(11):1–20. doi:10.3390/S22114062.

- Manowska A. 2020. Using the lstm network to forecthe demand for hard coal. *Gospodarka Surowcami Mineralnymi / Mineral Resources Management*. 36(4):33–48. doi:10.24425/gsm.2020.133945.
- Mehmood F, Ahmad S, Whangbo TK. 2023. An efficient optimization technique for training deep neural networks. *Mathematics*. 11(6):1–22. doi:10.3390/MATH11061360.
- Nabipour M, Nayyeri P, Jabani H, Shahab S, Mosavi A. 2020. Predicting Stock Market Trends Using Machine Learning and Deep Learning Algorithms Via Continuous and Binary Data; A Comparative Analysis. *IEEE Access*. 8:150199–150212. doi:10.1109/ACCESS.2020.3015966.
- Patterson J, Gibson A. 2017. *Deep Learning: A Practitioner's Approach*. Ed ke-1. Loukides M, McGovern T, editor. Sebastopol (CA): O'Reilly Media.
- Poon S-H. 2005. *A Practical Guide to Forecasting Financial Market Volatility*. Ed ke-1. West Sussex: John Wiley & Sons Ltd.
- Prado ML de. 2018. *Advances in Financial Machine Learning*. New Jersey (NJ): John Wiley & Sons, Inc.
- Puspitasari IF, Andriyani N, Hidayah N. 2022. Emas sebagai safe haven dan inflation hedging di tengah ketidakpastian perekonomian global selama pandemi covid-19. *JURNAL PENDIDIKAN EKONOMI: Jurnal Ilmiah Ilmu Pendidikan, Ilmu Ekonomi dan Ilmu Sosial*. 16(2):250–258. doi:10.19184/JPE.V16I2.33694.
- Qasem O Al, Akour M, Alenezi M. 2020. The Influence of Deep Learning Algorithms Factors in Software Fault Prediction. *IEEE Access*. 8:63945–63960. doi:10.1109/ACCESS.2020.2985290.
- Rijn JN van, Hutter F. 2018. Hyperparameter importance across datasets. Di dalam: *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. London, United Kingdom: Association for Computing Machinery. hlm 2367–2376.
- Sanghvi R. 2021. A Complete Guide to Adam and RMSprop Optimizer | by Sanghvirajit | Analytics Vidhya | Medium. [diakses 2023 Jun 4]. <https://medium.com/analytics-vidhya/a-complete-guide-to-adam-and-rmsprop-optimizer-75f4502d83be>.
- Sarangapani J. 2006. *Neural Network Control of Nonlinear Discrete-Time Systems*. Boca Raton (FL): Taylor & Francis Group.
- Schmuller J. 2017. *Statistical Analysis with R*. Hoboken (NJ): John Wiley & Sons, Inc.
- Soelistijo UW, Anjani PL, Pratama HI, Pili H La, Herdyanti MK. 2015. Trend of mineral commodity price and its impact on the Indonesia economy 1990–2025. *Earth Sciences*. 4(4):129–145. doi:10.11648/j.earth.20150404.11.
- Szczygielski JJ, Enslin Z, Du Toit E. 2018. An investigation into the changing relationship between the gold price and South African gold mining industry returns. *South African Journal of Business Management*. 49(1):1–11. doi:10.4102/SAJBM.V49I1.232.
- Vidya GS, Hari VS. 2020. Gold price prediction and modelling using deep learning techniques. Di dalam: *2020 IEEE Recent Advances in Intelligent Computational Systems, RAICS 2020*. Thiruvananthapuram, India: Institute of Electrical and Electronics Engineers Inc. hlm 28–31.
- Wahyuningsih S, Goejantoro R, Siringoringo M, Saputra AR, Aminah S. 2019.

Application seasonal autoregressive integrated moving average to forecast the number of East Kalimantan hotspots. *Journal of Physics: Conference Series*. 1351(1):1–5. doi:10.1088/1742-6596/1351/1/012085.

World Bank. 2023. *Commodity Markets Outlook*. Washington (DC): World Bank Group.

World Gold Council. 2023. Gold Spot Prices & Market History | World Gold Council. [diakses 2023 Jan 20]. <https://www.gold.org/goldhub/data/gold-prices>.

Yulian I, Anggraeni DS, Aini Q. 2020. Penerapan metode trend moment dalam forecasting penjualan produk CV. Rabbani Asyisa. *JURTEKSI (Jurnal Teknologi dan Sistem Informasi)*. 6(2):193–200. doi:10.33330/JURTEKSI.V6I2.443.

Yurtsever M. 2021. Gold price forecasting using lstm, bi-lstm and gru. *European Journal of Science and Technology*. 31(1):341–347. doi:10.31590/EJOSAT.959405.

Zahara S, Sugianto, M. Bahril Ilmiddafiq. 2019. Prediksi indeks harga konsumen menggunakan metode long short term memory (lstm) berbasis cloud computing. *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*. 3(3):357–363. doi:10.29207/resti.v3i3.1086.